

Q2.2)

Temos que a ELM tem um desempenho de classificação mais alto do que a regressão linear, pois nela utilizamos a tangente hiperbólica (\tanh) para mapear as entradas e os pesos dos neurônios para a última camada de pesos. Esta função é útil pois ela impede que pesos de neurônios sejam muito grandes, assim impedindo que alguns poucos pesos causam classificações incorretas.

Já a diminuição do tempo de execução pode ser atrelado às dimensões da matriz W (de pesos da camada final). Considerando todas as operações matriciais que são realizadas durante o treinamento, a diminuição de 785 para 501 faz uma grande diferença.

Q2.2)

Temos que o coeficiente de regularização no caso da regressão linear (891.4438) é maior do que no caso da ELM (32). Além disso, é sabido que quanto maior o posto da matriz utilizada no cálculo de W ($H=X*\text{neuron_weights}$ no caso da ELM e X na regressão), menor a necessidade da atuação do coeficiente de regularização. O posto de H é maior do que o de X , o que justifica o fato de $\lambda_{\text{ELM}} < \lambda_{\text{RLin}}$.

Q2.3)

Se a matriz de pesos dos neurônios for alterada, temos que o coeficiente de regularização também será alterado. Entretanto, não haverá uma mudança muito grande, pois o “range” dessa variação será proporcional ao desvio padrão utilizado (0.2 neste caso).